

P&P — Los datos originales, sin filtrar

Sep 29, 2026 · @Matias

Las cuatro fuentes tal como existen antes de cualquier trabajo nuestro. Todas las cifras de esta página están **medidas sobre los archivos**, no estimadas.

Lo primero que hay que aclarar, porque cambia lo que se puede entregar: **de las cuatro, solo dos existen como archivo original descargado**. Las otras dos no son fuentes que alguien publique — las construimos nosotros.

Las cuatro fuentes

Fuente	¿Hay original sin tocar?	Filas	Peso	
Billboard Hot 100	Sí, descargado tal cual	355.000	19 MB	
Características del sonido	Sí, descargado tal cual	56.277.664	4,1 GB	
Premios Grammy	No existe: lo armamos nosotros	2.513	147 KB	
Grupo de control	No existe: lo construimos nosotros	—	—	

1. Billboard Hot 100 — original completo

El ranking semanal de las 100 canciones más escuchadas en Estados Unidos, sin interrupción desde agosto de 1958. **Una fila por canción y por semana**, no una fila por canción.

Origen	github.com/utdata/rwd-billboard-data
Archivo en el origen	data-out/hot-100-current.csv
Descargado	18 de agosto de 2026
Licencia	MIT License
Atribución	Christian McDonald · School of Journalism and Media, University of Texas at Austin

Sus 7 columnas, tal cual vienen:

```
chart_week,current_week,title,performer,last_week,peak_pos,wks_on_chart
2022-01-01,1,All I Want For Christmas Is You,Mariah Carey,1,1,50
2022-01-01,2,Rockin' Around The Christmas Tree,Brenda Lee,2,2,44
2022-01-01,3,Jingle Bell Rock,Bobby Helms,4,3,41
```

Se ve enseguida por qué hay 355.000 filas para 32.702 canciones: *All I Want For Christmas Is You* aparece una vez por cada una de sus 50 semanas en el ranking. Nuestro trabajo sobre este archivo fue colapsarlo a una fila por canción, con el mejor puesto, las semanas totales y el año de primera aparición.

2. Características del sonido — original completo

Los valores numéricos que describen cómo suena cada canción. **No contiene audio**: son los números que el algoritmo de Spotify ya calculó sobre su catálogo.

Origen	huggingface.co/datasets/GildasLeDrogoff/spotify-huge-track-analysis-dataset
Descargado	18 de agosto de 2026
Licencia	CC BY-NC 4.0 — atribución, uso no comercial
Atribución	Gildas Le Drogoff · datos originales calculados por Spotify
Medido	56.277.664 filas · 27 columnas · 4,1 GB

Sus 27 columnas: `track_id`, `artist_name`, `track_name`, `album_name`, `album_release_date`, `duration_ms`, `explicit`, `track_number`, `disc_number`, `track_popularity`, `album_popularity`, `track_vs_album_popularity`, `artist_popularity`, `artist_followers`, `album_vs_artist_popularity`, `tempo`, `key`, `mode`, `danceability`, `energy`, `loudness`, `speechiness`, `acousticness`, `instrumentalness`, `liveness`, `valence`, `energy_danceability_score`.

Las dos primeras filas del archivo, tal como salen:

```
track_name,artist_name,album_release_date,tempo,energy,danceability,acousticness,valence,loudness
Raisin: Runnin' to Meet the Man,Howard Roberts,1973-01-01,134.684,0.505,0.588,0.636,0.778,-11.183
Raisin: Runnin' to Meet the Man,Joe Morton,1973-01-01,134.684,0.505,0.588,0.636,0.778,-11.183
```

Esas dos filas ya muestran el problema principal de la fuente: **la misma grabación repetida con distinto artista acreditado**. Multiplicado por 56 millones, con remasterizaciones, versiones en vivo y recopilatorios, es lo que más tiempo llevó del proyecto. Era el nombre del productor y no del artista, se tuvo que verificar cada canción.

Quién analizó las canciones. No fuimos nosotros: fue Spotify. Su sistema procesó su catálogo y calculó estos valores para sus propias recomendaciones, y los publicaba por su API hasta que **cerró el acceso en noviembre de 2024**. Alguien los había cosechado antes en este dataset, que es la única vía que queda.

3. Premios Grammy — no existe un original

Ningún dataset público tenía lo que necesitábamos. Los de Kaggle exigen cuenta y varios traen solo ganadores; el más completo que encontramos, `pezon/music-mining`, cubre únicamente 2000–2022 con 457 nominados. Sin las seis décadas la hipótesis no se puede ni probar ni refutar.

Así que lo armamos nosotros, parseando una página de Wikipedia por categoría con `scripts/fetch_grammy.js`.

Origen	Wikipedia, 16 páginas de categoría (14 devolvieron datos)
Licencia	CC BY-SA 4.0
Atribución	Wikipedia — Los colaboradores de Wikipedia
Medido	2.513 nominaciones, de las cuales 488 ganaron, 1959–2026

El archivo que tenemos es la extracción cruda. No le aplicamos ningún filtro: es todo lo que Wikipedia trae en esas categorías, nominadas y ganadoras por igual. Lo único más "original" que esto sería el texto en bruto de las 16 páginas, en formato de marcado de Wikipedia — ilegible para una persona, pero se puede generar si hace falta.

```
anio,categoria,titulo,artista,ganador
1959,Record of the Year,Nel Blu Dipinto Di Blu (Volare),Domenico Modugno,1
1959,Record of the Year,Catch a Falling Star,Perry Como,0
1959,Record of the Year,The Chipmunk Song (Christmas Don't Be Late),David
Seville,0
```

4. Grupo de control — no existe, y no puede existir

Nadie publica un dataset de "canciones que no ganaron nada ni fueron hit". Es una categoría que solo tiene sentido dentro de este proyecto, definida por ausencia.

Sale enteramente del dump de características. La cadena completa, leída del script:

Paso	Quedan
Dump crudo de características	56.277.664
Desde 1970, con título y artista presentes	
Deduplicado por título + artista, se conserva la más popular	
Se borran las que aparecen en Grammy o en Billboard	8.893.628 ← el pozo
Se sacan audiolibros y no-música: menos de 1 minuto o más de 15	
Muestreo al azar de 4.500 por década, seis décadas	27.000

El paso que define todo es el cuarto: el control es **lo que queda del dump cuando se saca todo lo premiado y todo lo que entró al ranking.**

Cómo obtener los dos que no se pueden mandar

Archivo	Peso	Cómo
Características del sonido	4,1 GB	Descargar del link de la fuente 2
Pozo de control	669 MB	<code>node scripts/armar_control1.js</code> (~12 min, requiere el anterior)