

P&P — Datos y referencias

Documento único y autocontenido: **todos los datos que usamos** (de dónde salen, por qué elegimos esos, qué problemas tienen, para qué sirve cada uno) y **todas las referencias** (las herramientas técnicas que usamos y los referentes de diseño y producto).

Escrito para alguien que arranca de cero. Cada término técnico se explica la primera vez que aparece, y hay un glosario al final.

El detalle de los problemas encontrados y los resultados del análisis está en `PLAN-DE-DATOS.md`.

Actualizado: 3 de septiembre de 2026

PARTE A — LOS DATOS

A.0 Antes que nada: cómo pensar el problema

La app promete que el usuario sube una canción y recibe dos puntajes: cuánto se parece al perfil que premia el Grammy y cuánto al que triunfa comercialmente.

Para poder decir eso, hay que enseñarle al sistema cómo suena cada uno de esos dos mundos. Y se le enseña como se le enseñaría a una persona a distinguir vinos: no con teoría, sino haciéndole probar cientos de ejemplos con la respuesta puesta.

Todos los datos del proyecto terminan en una sola tabla, donde cada fila es una canción:

título	artista	año	energía	valencia	acústica	...	¿Grammy?	¿puesto Billboard?
Bohemian Rhapsody	Queen	1975	0,40	0,23	0,29	...	no	9
Rolling in the Deep	Adele	2011	0,77	0,51	0,14	...	ganó	1
(una canción cualquiera)	...	1998	0,55	0,44	0,31	...	no	—

Las columnas del medio son **las características del sonido**: lo que le damos al sistema. Las dos últimas son **las respuestas**: qué le pasó a esa canción en cada mundo.

La distinción más importante del proyecto: "el perfil que premia la Academia" **no es un dato que se descarga**. Es lo que el sistema deduce al mirar miles de filas. Si se pudiera bajar de algún lado, no habría proyecto. Lo que se baja son las canciones con sus características y sus respuestas.

Esa tabla se arma con **cuatro fuentes**, más una quinta que funciona distinto.

A.1 Fuente 1 — Billboard Hot 100 conseguida

Qué es

El ranking semanal de las 100 canciones más escuchadas en Estados Unidos. Existe sin interrupción **desde el 4 de agosto de 1958**.

De dónde lo sacamos

Del repositorio público [utdata/rwd-billboard-data](https://github.com/utdata/rwd-billboard-data) en GitHub. Es una descarga directa: gratis, sin cuenta, sin permisos.

Para qué sirve

Es el eje de la popularidad de la app. Cuando el gráfico ubica una canción más a la derecha o más a la izquierda en "éxito comercial", ese eje está construido con estos datos.

Por qué esta fuente y no la cantidad de reproducciones en Spotify

Esta es la decisión más importante de todas las fuentes, y conviene poder defenderla:

La hipótesis del proyecto compara **seis décadas**. Los datos de reproducciones (*streams*) existen desde 2015 más o menos. **No hay forma de saber cuántas veces se "reprodujo" una canción en 1967** — el concepto no existía. Billboard es la única medida de éxito comercial que existe en las seis décadas y que se midió siempre de la misma manera.

Y tiene una ventaja extra: da una medida **gradual**, no un sí o un no. Llegar al puesto 3 y quedarse 20 semanas no es lo mismo que asomar al puesto 87 durante dos semanas, y esa diferencia queda registrada.

Qué trae y qué hicimos con eso

El archivo original tiene **355.001 filas**, pero es la misma canción repetida semana a semana. Lo colapsamos a **una fila por canción: 32.702 canciones únicas**, cada una con:

- Su **mejor puesto** histórico (de 1 a 100)
- Cuántas **semanas** estuvo en el ranking
- El **año de su primera aparición** ← este dato resultó ser clave, ver A.3

Década	Canciones	Llegaron al top 10
1950s	925	147
1960s	6.850	1.059
1970s	5.301	941
1980s	4.113	969
1990s	3.424	671
2000s	3.418	591
2010s	4.431	522
2020s	4.240	417

Está parejo en todas las décadas, que es justo lo que hace falta para comparar épocas sin que una domine.

```
Archivo: data/raw/billboard-hot100.csv (19 MB) → data/billboard-canciones.csv · Script: preparar-billboard.js
```

A.2 Fuente 2 — Premios Grammy conseguida

Qué es

Las canciones nominadas y ganadoras del Grammy, desde la primera entrega en 1959 hasta la de 2026.

De dónde lo sacamos

Lo armamos nosotros, escribiendo un programa que baja las páginas de Wikipedia y las convierte en tabla.

Para qué sirve

Es el eje del prestigio de la app. El otro eje del gráfico.

Por qué nos lo armamos en vez de bajar uno hecho

Buscamos datasets ya armados y ninguno servía:

Opción	Por qué no
Datasets de Kaggle	Exigen crear una cuenta, y varios traen solo ganadores , no nominados
<code>music-mining</code> (GitHub)	Parecía ideal: ya venía cruzado con características de sonido y premios. Pero solo cubre 2000-2022 , con 457 nominados. Sin las seis décadas, la hipótesis no se puede ni probar ni refutar

Wikipedia tiene una página por cada categoría del Grammy, con una tabla que lista todos los años y todos los nominados. Es gratis, no pide cuenta, y es la fuente más completa que existe para los años viejos.

Qué conseguimos

2.514 nominaciones, de las cuales **488 ganaron**, entre 1959 y 2026, en **14 categorías**:

- **Generales** (premian una canción sin importar el género): Record of the Year, Song of the Year
- **De género**: rock, pop, R&B, country, rap, metal, alternativo, dance

Por qué nominados y no solo ganadores

Esto es clave y es fácil pasarlo por alto.

Ganadores de Canción del Año hay unos **60 en toda la historia**. Con 60 ejemplos un sistema no aprende nada: memoriza esos 60 casos y después falla con todo lo demás. Sumando nominados pasamos de 60 a más de 2.500 — **cuarenta veces más material**.

Y es más correcto conceptualmente. La hipótesis habla del *perfil de sonido que la Academia reconoce*, y **una nominación ya es reconocimiento**: significa que un comité de la industria eligió esa canción entre miles. Que gane una de las cinco finalistas depende de campaña, sello y política, cosas que ningún dato sobre el sonido puede capturar.

Cómo verificamos que está bien

Revisamos ganadores de todas las décadas contra lo que se sabe:

Año	Lo que devolvió el programa
1959	Nel Blu Dipinto Di Blu (Volare) — Domenico Modugno ✓
1965	The Girl from Ipanema — Stan Getz & Astrud Gilberto ✓
1984	Beat It — Michael Jackson ✓
2000	Smooth — Santana featuring Rob Thomas ✓
2020	Bad Guy — Billie Eilish ✓
2026	Luther — Kendrick Lamar & SZA ✓

Un error que costó encontrar y que vale contar

La primera versión del programa devolvía esto:

```
It's Too Late – Lou Adler, producer
```

En vez de **Carole King**, que es quien la canta. El motivo: en la tabla de Record of the Year, la última columna no es el intérprete sino el **equipo de producción**. Y las categorías no comparten estructura:

Record of the Year:	Año	Grabación	Artista	Equipo de producción
Song of the Year:	Año	Canción	Compositores	Artista

Tomar "la última columna" da el productor en un caso y el artista en el otro. Con el productor en lugar del artista, el cruce con la fuente 3 habría fallado casi entero y no habríamos sabido por qué. Se arregló leyendo los **encabezados** de cada tabla para identificar la columna correcta.

```
Archivo: data/raw/grammy-nominaciones.csv · Script: fetch-grammy.js (se puede volver a correr cada año cuando salgan los nuevos Grammy)
```

A.3 Fuente 3 — Características del sonido conseguida

Qué es

Una tabla gigante donde cada fila es una canción y las columnas son **números que describen cómo suena**.

De dónde lo sacamos

Del dataset público [GildasLeDrogo/spotify-huge-track-analysis-dataset](#), alojado en **HuggingFace**: 56.277.664 canciones, 4,1 GB, sin cuenta ni credenciales.

Para qué sirve

Son las **variables del modelo**: lo que el sistema mira para encontrar los patrones. Y son exactamente lo que la app le muestra al usuario cuando le dice *"tu energía te suma en popularidad y te resta en prestigio"*.

Importante: no contiene música

Nadie nos manda 56 millones de canciones. Nos manda **los números que ya estaban calculados** a partir de ellas. Por eso son 4 GB y no varios petabytes. Adentro se ve así:

track_name	artist_name	album_release_date	energy	valence	acousticness	tempo
Bohemian Rhapsody	Queen	2024-07-19	0.402	0.228	0.289	143.9

¿Quién analizó las canciones? Spotify, no nosotros

Es la pregunta que más se hace sobre el proyecto, así que conviene tenerla clara: **nosotros no analizamos ninguna canción**. La cadena es esta:

1. **Spotify analizó el audio**. Durante años su sistema procesó cada canción de su catálogo y calculó automáticamente estos valores. Lo hacía para sus propias recomendaciones.
2. **Los publicaba por su API**. Cualquier programador podía pedirle las características de una canción y Spotify devolvía los números.
3. **Alguien los cosechó**. Un usuario de HuggingFace le pidió a esa API los datos de millones de canciones y armó la tabla. Eso es lo que bajamos.
4. **En noviembre de 2024 Spotify cerró el acceso** (ver abajo), y el archivo quedó como una foto tomada antes del cierre.

Precisión al hablar de esto. Los 56 millones son el tamaño de la fuente, no de nuestro trabajo: usamos **8,9 millones** como referencia de época y **53.577** como material de aprendizaje. Decir "analizamos 56 millones de canciones" sería falso.

Y la limitación que arrastra: nunca pudimos verificar ese algoritmo. Confiamos en que su "energía 0,82" mide lo que dice medir, pero es una **caja negra** — Spotify nunca publicó el método. No podemos reproducir esos números desde cero, y es la razón de fondo por la que hay que calibrar contra librosa (sección A.5): estamos combinando un instrumento que no podemos inspeccionar con otro que sí.

Por qué no se lo pedimos directamente a Spotify

Porque ya no se puede. En noviembre de 2024 Spotify **cerró el acceso** a estos datos para las aplicaciones nuevas. Una app creada hoy no se los puede pedir. Los datasets como este se armaron antes de ese cierre, y son la única forma de acceder a esa información ahora.

Y aunque estuviera abierto, no alcanzaría: **la canción que sube el usuario puede ser un demo sin publicar**, que no está en Spotify. Eso se resuelve con la fuente 5.

Por qué este dataset y no otro

Comparamos varios candidatos:

Candidato	Tamaño	Por qué sí o no
maharshipandya/spotify-tracks-dataset	13 MB, 114.000 canciones	❌ Cómodo, pero no tiene el año . Sin año no se puede comparar 1965 con 2025, que es exactamente lo que la hipótesis necesita
oze/spotify_audio_features	12 GB, 255 millones	❌ Más de lo necesario y mucho más pesado de manejar
GildasLeDrogoff	4,1 GB, 56 millones	✅ Tiene año, artista, título y las características. Tamaño manejable

Las diez características que usamos, una por una

Casi todas van de 0 a 1, donde 0 es nada y 1 es el máximo. Están ordenadas por **cuánto separan** a las canciones premiadas de los hits — medido sobre el corpus, no supuesto:

Característica	Qué mide, en criollo	Separación	Ejemplo
Energía	Qué tan intensa y activa suena	0,473	Metal $\approx 0,95$ · balada de piano $\approx 0,15$
Valencia	Qué tan alegre suena. No es la letra, es el sonido	0,461	Canción de fiesta $\approx 0,9$ · melancólica $\approx 0,2$
Acústica	Probabilidad de que use instrumentos reales en vez de electrónicos	0,349	Guitarra y voz $\approx 0,9$ · electrónica $\approx 0,02$
Duración	Cuánto dura	0,344	—
Bailabilidad	Qué tan regular y marcado es el ritmo	0,215	Reguetón $\approx 0,85$ · rock progresivo $\approx 0,3$
Volumen	Nivel promedio en decibeles (número negativo: cuanto más cerca de 0, más fuerte)	0,171	Pop moderno ≈ -5 dB · grabación de los 60 ≈ -13 dB
Habla	Cuánta palabra hablada tiene en vez de cantada	0,164	Rap $\approx 0,3$ · pop $\approx 0,04$ · audiolibro $> 0,66$
Tempo	Velocidad, en pulsos por minuto	0,061	Balada ≈ 70 · house ≈ 128
Modo	Mayor (suele sonar alegre) o menor (suele sonar triste)	0,037	—
Instrumentalidad	Probabilidad de que no tenga voz cantada	0,036	Instrumental $\approx 0,9$ · canción normal $\approx 0,0$

Las cuatro primeras son las que explican el resultado, y son las que la app le muestra primero al usuario en la lista de "qué suma y qué resta". Las tres últimas aportan casi nada por separado, pero se mantienen porque pueden rendir combinadas — el tempo solo no distingue, pero cruzado con la energía puede separar un tema intenso y lento de uno intenso y rápido.

Dos que sacamos, y por qué

Sacada	Motivo
Tonalidad	Viene como un número del 0 al 11 (Do es 0, Do# es 1, y así). El modelo lo leería como una cantidad , y creería que el 11 está muy lejos del 0 — cuando musicalmente Si y Do son vecinos. No aporta información: mete ruido
En vivo	Al deduplicar sacamos a propósito las tomas en vivo, así que en el corpus casi no varía: solo el 0,8% pasa de 0,8. Separaba 0,128, de las más bajas

Una que agregamos: la rareza

Qué mide. Cuán lejos está una canción del centro de su propio año, en las nueve características continuas a la vez. La referencia son las 8,9 millones del pozo agrupadas por año — o sea **toda la música publicada ese año**, no solo los hits. Un valor alto significa "no sonaba como nada de lo que se hacía entonces".

Por qué la agregamos. Como hipótesis propia y comprobable: quizá la Academia premia lo que se sale de la norma y el público lo que se le parece.

Qué dio. Separación 0,077 — la más baja de todas. Y en dirección contraria a lo esperado: las premiadas de categorías generales son *ligeramente menos* raras (0,768) que los hits (0,785). Por década tampoco hay tendencia.

La hipótesis se cae: la Academia no premia lo que se sale de la norma. Es un resultado negativo y se reporta como tal.

Pero la medida funciona. Las canciones que salieron como más raras son coherentes: *Baile Inolvidable* de Bad Bunny (una salsa en el Hot 100), *Honeycomb* de Deafheaven (blackgaze), *Junk Food Junkie* de Larry Groce (una canción novelty). Está midiendo rareza de verdad; simplemente la rareza no predice premios.

Una limitación de diseño que probablemente lo explique. La rareza, como está definida, es ciega a la dirección: mide distancia al centro sin importar hacia dónde. Una canción muy acústica y una muy electrónica dan la misma rareza alta, siendo opuestas. Si las premiadas son raras hacia lo acústico y largo, y los hits hacia lo energético y bailable, al colapsar todo en una distancia esas dos rarezas se cancelan.

Se queda igual, por dos motivos: ya está calculada y puede rendir combinada con otras, y como información al usuario sirve más allá de que prediga premios — "*tu canción es más rara que el 90% de lo que se publicó este año*" es algo que un músico quiere saber.

Los dos problemas que trajo esta fuente

Problema 1: el año que trae no es el año de la canción.

Al buscar *Bohemian Rhapsody* el dump devolvió fecha 2024 y 2025. La canción es de 1975. Ese campo es la fecha de la edición en Spotify: remasterizaciones y recopilatorios.

Lo medimos en vez de suponer, comparándolo contra el año real de Billboard:

Década	Acierta dentro de ± 3 años
1950s	0% (se desvía 12 años)
1960s	21% (se desvía 8 años)
1970s	80%
1980s	88%
1990s	92%
2000s	95%
2010s	96%
2020s	98%

Sirve desde 1970 y falla antes. El motivo: las grabaciones anteriores a 1970 llegaron a Spotify como reediciones digitales hechas décadas más tarde.

Cómo lo resolvimos: el año lo ponen Billboard y Grammy, que lo tienen exacto. **El dump aporta el sonido; el año viene de otro lado.**

Problema 2: cada canción aparece muchas veces.

La misma búsqueda devolvió tres Bohemian Rhapsody: dos remasterizaciones y una versión en vivo. Y los números son completamente distintos: **energía 0,85 en vivo contra 0,40 en estudio.**

Cómo lo resolvimos: una sola versión por canción. Se descartan las que dicen "live", "remix", "karaoke", "cover", "instrumental" o "demo" en el título, y entre las que quedan se elige la más popular, que es la grabación de estudio original. De 56 millones de filas quedaron **43.618.889 canciones únicas.**

Archivo: `data/raw/spotify-features.parquet` (4,1 GB)

A.4 Fuente 4 — El grupo de control conseguida

Qué es

Canciones que no ganaron nada y nunca fueron hit. Las comunes.

Por qué es imprescindible (y por qué casi nadie lo ve venir)

Con Grammy y Billboard tenemos las que ganaron y las que fueron éxito. Parece completo. **No lo es.**

Si al sistema solo le mostramos ganadoras y exitosas, nunca ve cómo suena una canción normal, y entonces **no tiene contra qué comparar.** Todo lo que le entre va a puntuar alto en algo.

Es como enseñarle a alguien a reconocer caras famosas mostrándole únicamente fotos de famosos: cuando le mostrás a un desconocido, va a decir que también es famoso, porque no sabe cómo se ve alguien que no lo es.

Sin este grupo, los dos puntajes de la app **no significan nada**. Y lo peor es que **no se nota**: los números salen, se ven razonables, el gráfico se dibuja bien. El error es invisible desde la pantalla.

De dónde sale

Gratis, del mismo dump de la fuente 3. Todas las canciones que están ahí y **no** aparecen ni en Grammy ni en Billboard son, por definición, canciones que no ganaron ni fueron hit.

Qué armamos

Del dump salieron **8.893.628 candidatas**. De ahí se filtró lo que no es música y se tomaron **27.000: 4.500 por década, de 1970 a hoy**, para que ninguna época domine.

Por qué desde 1970: estas canciones no están en Billboard ni en Grammy, así que **no tienen año por ningún lado** que la fecha del dump — y esa fecha falla antes de 1970 (ver A.3).

El problema que trajo: no todo lo que está en Spotify es música

Al mirar una muestra al azar del primer grupo de control apareció esto:

'028 - und die geheimnisvolle Stadt - Teil 36'	– Fünf Freunde	(1991)
'Uterine Sounds'	– Relaxing Radiance	(2020)

La primera es un **audiolibro infantil alemán**. La segunda es **ruido blanco para dormir**.

Por qué es grave. Si el grupo de control tiene audiolibros, el modelo aprende que "no ser un hit" significa "ser palabra hablada". Eso es facilísimo de detectar, así que el modelo se vería muy preciso y **sería completamente inútil**: estaría respondiendo "*¿esto es música?*" en vez de "*¿esto suena a hit?*".

Lo medimos: **5,8% del control era palabra hablada, contra 0,05% de los hits**. Ciento dieciséis veces más.

Y el error que cometimos al intentar arreglarlo

El primer filtro fue la regla obvia: "*muy instrumental y con poca energía*". Al revisar qué agarraba:

London Symphony Orchestra	– banda sonora de Indiana Jones
La Petite Bande	– Lully, Le Bourgeois Gentilhomme
Erik Satie	– Gnossienne No. 2

Eso no es ruido: es **música clásica**. La regla describe igual de bien a un generador de ruido blanco que a una pieza de piano de Satie. Si la aplicábamos, sacábamos del control toda la música tranquila e instrumental, y el modelo habría aprendido que "no ser hit" significa "tener voz y ser movida". Sesgo puro.

Cómo quedó resuelto. Se descartó esa regla. Los filtros finales son deliberadamente conservadores — prefieren dejar pasar algo de ruido antes que borrar música legítima:

Filtro	Qué saca
Palabra hablada > 0,66	Audiolibros y radioteatros. Es el umbral que Spotify define como "enteramente hablado"
Menos de 1 minuto	Fragmentos, intros, capítulos partidos
Más de 15 minutos	Capítulos de audiolibro y sesiones de DJ. Deja pasar prog rock y clásica larga
Nombre de artista de fábrica	"White Noise Baby Sleep", "Womb Sounds Heartbeat". Busca en el artista , no en el título, para no pisar canciones que se llamen <i>Rain</i> o <i>Sleep</i>

Auditado: de las 384.814 canciones instrumentales y tranquilas del pozo, el filtro toca solo el **8%**. Lo que borra es "*Box Fan - Loopable*" de "Vacuum Cleaner White Noise"; lo que deja son grabaciones de piano de baja repercusión, que **corresponde** que estén ahí porque efectivamente no son hits ni ganaron nada.

Un regalo que salió del cruce

Las canciones que están en Grammy y en Billboard son las que lograron las dos cosas. Esa es directamente la funcionalidad "*casos que lograron las dos cosas*" de la app, y además es la prueba de qué tan rara es esa combinación. No hubo que recolectarla: apareció sola. **Son 1.071.**

```
Archivo final: data/control-v2.csv (mismo esquema que el corpus, se pueden apilar) · intermedio
data/control.csv · pozo completo data/pozo-control.parquet · scripts armar-control.js + armar-
control-v2.js
```

A.5 Fuente 5 — La canción que sube el usuario pendiente

Por qué es completamente distinta

Las cuatro fuentes anteriores arman el **corpus histórico**: lo que el sistema estudia. Esta es otra cosa: **el archivo que el usuario sube en el momento.**

Ahí no hay dataset que valga. Puede ser un demo que no existe en ningún lado, que nunca se publicó, que no está en Spotify. Hay que **analizar el audio directamente**, en nuestro servidor.

Con qué

Con **librosa** o **Essentia**: programas gratuitos y de código abierto que abren un archivo de audio y calculan las mismas características (duración, velocidad, energía, brillo del sonido, dinámica).

Qué falta para tenerlo

librosa funciona con **Python**, que hoy **no está instalado** en la máquina. Para bajar y cruzar los datos alcanzó con otra herramienta, pero antes de que la app pueda analizar una canción de verdad hay que instalarlo.

El problema técnico más importante que queda abierto

Los números del corpus los calculó **el algoritmo de Spotify**. Los del usuario los va a calcular **librosa**. Son programas distintos: su "energía" y la "energía" de Spotify miden cosas parecidas de maneras distintas.

Si entrenamos con una escala y medimos con otra, **la app devuelve números mal calibrados**. Otra vez: se ven razonables, están mal.

Cómo se resuelve. Tomar unas cien canciones que estén en el dump y de las que tengamos el audio, analizarlas con **librosa**, y medir cómo se traduce una escala a la otra. Con esa equivalencia se ajustan los números del usuario antes de pasarlos al modelo. Es una tarea acotada, **no se puede saltar**, y hay que dejarla escrita en la página de racional.

Qué pasa con el archivo del usuario

Se sube, se procesa, se descarta. **Hay que decirlo en la pantalla**: nadie sube un demo inédito a una web sin saber qué pasa con él, y decirlo genera confianza en usuarios que son muy cuidadosos con su material.

A.5b Cómo leer los archivos: las 21 columnas y las celdas vacías

Los dos archivos finales — `corpus-v2.csv` y `control-v2.csv` — tienen **exactamente las mismas 21 columnas en el mismo orden**, así que se pueden apilar directamente para entrenar: 53.577 canciones en total.

Columna	Qué es
<code>titulo</code> , <code>artista</code> , <code>anio</code>	Identidad. El año es el de la primera aparición en Billboard, o el de la premiación
<code>grammy_gano</code> , <code>grammy_nominada</code>	1 o 0
<code>grammy_categorias</code>	En qué categorías fue nominada, separadas por <code> </code>
<code>mejor_puesto</code> , <code>semanas_en_chart</code> , <code>fue_hit</code>	Su paso por el Billboard Hot 100
<code>grupo</code>	<code>premiada</code> · <code>hit</code> · <code>ambas</code> · <code>control</code> . Es el resumen: dice de un vistazo qué es cada canción
Las 10 características	<code>danceability</code> , <code>energy</code> , <code>valence</code> , <code>acousticness</code> , <code>instrumentalness</code> , <code>speechiness</code> , <code>loudness</code> , <code>tempo</code> , <code>mode</code> , <code>duration_ms</code>
<code>rareza</code>	Cuán lejos está del centro de su año

Las celdas vacías son correctas, no son datos faltantes

Al abrir los archivos en Excel se ven columnas con celdas en blanco. **Ninguna es un error**, pero conviene saber por qué está vacía cada una:

Columna	Vacía en	Por qué
grammy_categorias	100% del control, 93,7% del corpus	Son las canciones que nunca fueron nominadas . No hay categoría que poner
mejor_puesto	100% del control, 2,2% del corpus	Son las que nunca entraron al ranking . Dejarlo vacío es lo correcto: poner 0 o 101 sería inventar una posición que no existe. En el corpus son exactamente las 593 del grupo premiada — nominadas que no llegaron al Hot 100
rareza	23,2% del corpus	Son las anteriores a 1970 . La rareza se mide contra la música de cada año, y antes de 1970 el pozo no tiene un año confiable (ver A.3). Como el modelo se entrena desde 1970, esas filas quedan fuera igual

Una que sí estaba mal y se corrigió: `semanas_en_chart` aparecía vacía para las canciones que nunca charteaban. Ahora dice **0**, que es el dato verdadero — esa canción efectivamente estuvo cero semanas en el ranking. La diferencia importa: vacío significa "no sabemos", cero significa "sabemos que fue ninguna".

A.6 Para qué sirve cada dato, pantalla por pantalla

Pantalla de la app	Qué datos usa	Cómo
Los dos puntajes	Todo el corpus	El sistema aprendió qué características acompañan a cada resultado. Le pasamos las de la canción del usuario y devuelve dos probabilidades
El margen de error ("32%, entre 24% y 41%")	El corpus	Sale de medir cuánto se equivoca el sistema con canciones que nunca vio. Es la promesa de honestidad de la app y no es opcional
El gráfico de dos ejes	Corpus + canción del usuario	Cada canción histórica es un punto. La del usuario es otro punto en el mismo plano
Lista de qué suma y qué resta	El modelo entrenado	Se calcula cuánto cambia cada puntaje al mover una sola característica dejando el resto igual
"Tu conflicto principal es la energía"	El modelo entrenado	Es la característica que más empuja los dos puntajes en direcciones opuestas . Es el corazón de la app: la tensión
Canciones de referencia	El corpus	Se buscan las más parecidas dentro de cada grupo (premiadas, exitosas, ambas). No hace falta ningún dataset extra
Simular cambios	El modelo entrenado	Cada vez que el usuario mueve un control, se recalculan los dos puntajes
Modo álbum	El modelo entrenado	Lo mismo para varias canciones, ordenadas
Explorar la historia	Corpus agrupado por año	Dos líneas: el promedio de las premiadas y el de las exitosas. La distancia entre ellas es la hipótesis hecha gráfico
El asistente conversacional	Resultados + acceso al modelo	Recibe los números ya calculados y los traduce a lenguaje de músico. Cuando el usuario pregunta "¿y si bajo la energía?", le pide al modelo que recalcule y responde con el número real

La regla que atraviesa todo: los números los calcula el modelo, siempre igual. La inteligencia artificial conversacional **interpreta y traduce, nunca calcula ni decide**. Todo número que aparezca en pantalla se puede reproducir sin llamar a un modelo de lenguaje.

Esto importa por dos razones prácticas. Una: en una demo en vivo, los resultados dan siempre lo mismo. Dos: cuando pregunten "*¿y esto no lo inventa la IA?*", la respuesta es no, y se puede demostrar.

A.7 Qué NO recolectamos, y por qué

Sirve tanto como la lista de lo que sí, porque evita perder semanas:

- **Las letras.** La app mide sonido, no texto. Está declarado como límite, y el asistente tiene instrucciones de decir *"eso está fuera de lo que el análisis mide"*.
 - **Sello discográfico, presupuesto, campaña de prensa.** Pesan muchísimo en un Grammy real, pero no son características del sonido. Reconocerlo abiertamente es lo que hace honesta a la herramienta.
 - **Cantidad de reproducciones.** Redundante con Billboard, y no existe antes de 2015.
 - **Un dataset de "canciones de referencia".** Salen del mismo corpus.
 - **Datos personales de los usuarios.** No hacen falta para que la app funcione.
 - **El rango dinámico** (la distancia entre las partes suaves y las fuertes). Lo habíamos propuesto porque es el mejor indicador de la diferencia entre "grabación que la crítica valora" y "grabación pensada para radio". **No se puede:** el dump no lo trae, y calcularlo exigiría tener el audio de las 50.000 canciones del corpus, cosa que no tenemos ni podemos tener legalmente. Queda el **volumen promedio**, que captura parte del mismo fenómeno. Vale mencionarlo en la presentación: muestra que entendemos qué mide y qué no mide la herramienta.
-

PARTE B — LAS REFERENCIAS

B.1 Las herramientas que usamos para construir esto

Todo lo de la Parte A se hizo con estas herramientas. **Todas gratis y sin cuenta**, salvo la última.

Herramienta	Qué es, en criollo	Para qué la usamos	Estado
Node.js	El programa que permite ejecutar código JavaScript fuera del navegador. Es el "motor" donde corren nuestros scripts	Todos los scripts de descarga, parseo y cruce	✓ instalado
DuckDB	Una base de datos que no necesita servidor: es un archivo y listo. Está diseñada para analizar tablas enormes en una computadora común	Cruzar los 56 millones de canciones con Billboard y Grammy. Sin esto habría sido inviable	✓ instalado
Parquet	Un formato de archivo para tablas gigantes. Ocupa mucho menos que un CSV y se consulta más rápido, porque guarda los datos por columna en vez de por fila	El dump de 4,1 GB viene en este formato	✓
HuggingFace	Una plataforma donde la gente publica datasets y modelos de inteligencia artificial para que otros los usen. Es como GitHub pero para datos	De ahí sacamos las características del sonido	✓
GitHub	La plataforma donde los programadores publican y comparten código. Mucha gente también publica datos ahí	De ahí sacamos Billboard	✓
API de Wikipedia	Una forma de pedirle a Wikipedia el contenido de una página en formato que un programa pueda leer, en vez de leerlo a ojo	De ahí sacamos las 2.514 nominaciones al Grammy	✓
librosa	Un programa gratuito que abre un archivo de audio y calcula sus características	Analizar la canción que sube el usuario	❑ falta
Python	Otro lenguaje de programación, el estándar para trabajo con datos y audio	Necesario para que funcione librosa	❑ falta instalar
API de Claude (Anthropic)	El modelo de lenguaje que va a impulsar el asistente conversacional	El chat que traduce los números a lenguaje de músico	❑ falta · la única que cuesta plata (centavos por consulta)

Una nota técnica que vale para la presentación. La primera versión de los scripts agrupaba los 43 millones de canciones de una sola vez y se quedaba sin memoria, volcando 22 GB al disco antes de abortar. Filtrar **antes** de agrupar bajó el tiempo de "se cuelga" a **11 segundos**. Es la diferencia entre pedirle a la base que ordene toda la biblioteca y pedirle que ordene solo el estante que nos interesa.

Fuentes de datos, con link directo

Fuente	Link	Licencia / acceso
Billboard Hot 100 completo	github.com/utdata/rwd-billboard-data	Público, sin cuenta
Grammy (páginas por categoría)	Wikipedia — Record of the Year y 15 páginas más	Público, licencia CC
Características del sonido	huggingface.co/datasets/GildasLeDrogo/spotify-huge-track-analysis-dataset	Público, sin cuenta
(descartado) <code>music-mining</code>	github.com/pezon/music-mining	Solo cubre 2000-2022
(descartado) <code>maharshipandya</code>	huggingface.co/datasets/maharshipandya/spotify-tracks-dataset	No tiene el año

B.2 Referentes de diseño y producto

Estos son los proyectos que miramos para decidir **cómo debería verse y comportarse la app**. La consigna pide referentes de diseño, interfaz, utilidad y datos: acá están los cuatro grupos, con qué le tomamos a cada uno.

Visualización de datos

Every Noise at Once — de Glenn McDonald, que trabajaba en Spotify *Qué es*: un mapa de casi seis mil géneros musicales ubicados en un plano de dos dimensiones. Cada punto se puede clicar para escucharlo. *Por qué es nuestro referente principal*: es **exactamente la idea del gráfico central de P&P** — ubicar música en un plano de dos ejes — y demuestra que funciona como interfaz. Alguien que nunca vio un gráfico de dispersión entiende ese mapa en diez segundos. *Qué le tomamos*: que el plano es navegable y que cada punto es una canción real que se puede reconocer, no un dato abstracto.

The Pudding *Qué es*: una publicación de ensayos visuales, muchos sobre música (la evolución del Billboard, cómo cambió la estructura de las canciones). *Qué le tomamos*: que **el hallazgo se cuenta como un argumento**, no como un tablero de control. El lector recorre el descubrimiento en vez de recibirlo servido. Es la referencia para el orden de las pantallas.

Gapminder — de Hans Rosling *Qué es*: un gráfico de burbujas con una línea de tiempo que se puede arrastrar, mostrando cómo cambiaron los países en salud y riqueza a lo largo de dos siglos. *Qué le tomamos*: es **el modelo exacto de la pantalla "Explorar la historia"**. Mover el tiempo y ver moverse los puntos es lo que hace entender un cambio histórico sin leer una sola cifra.

Datawrapper — [blog de Lisa Charlotte Muth](#) *Qué es*: artículos muy prácticos sobre cómo elegir colores, escalas y anotaciones en un gráfico. *Qué le tomamos*: decisiones concretas de color y escala. Es la referencia

técnica, no conceptual.

Comunicación de la incertidumbre

FiveThirtyEight — modelos de pronóstico electoral · [copia archivada del pronóstico 2020](#) · continúa en [Silver Bulletin](#)

⚠ El sitio original ya no existe: Disney cerró FiveThirtyEight en marzo de 2025 y borró el archivo en mayo de 2026. Usar la copia del Archivo de Internet. *Qué es:* el sitio que popularizó los pronósticos electorales expresados como probabilidades con rango, en vez de un ganador anunciado. *Por qué importa acá:* son quienes establecieron que **se comunica un rango, no un número**. La propuesta de P&P ya llegó por intuición a la misma decisión — "32%, con un margen entre 24% y 41%" — y citarlos convierte esa intuición en una **decisión de diseño fundamentada**, que es justo lo que la consigna pide poder defender. *Qué le tomamos:* que el margen se muestra siempre, no como letra chica.

Interfaz y producto

[iZotope Ozone — Tonal Balance Control](#) *Qué es:* una herramienta profesional de mezcla que compara tu tema contra la curva típica de un género y te muestra en qué te desvías. *Por qué es el mejor referente de utilidad:* es la misma idea de P&P aplicada a la mezcla, y es una herramienta que los músicos **ya usan y entienden**. Valida que el formato "tu track contra un perfil de referencia" es legible para el usuario objetivo, que es exactamente quien va a usar nuestra app.

[Spotify Wrapped](#) *Qué le tomamos:* cómo volver **personal** un resultado de datos. La diferencia entre "acá están tus números" y "esto es lo que dice tu año".

[Linear](#) *Qué es:* una herramienta de gestión de proyectos para equipos de software, conocida por su acabado. *Qué le tomamos:* densidad de información sin ruido visual, y pantallas vacías que enseñan a usar la app en vez de quedarse en blanco. Es la referencia de terminación de la interfaz.

Utilidad — el rubro donde compete

[Chartmetric](#) y [Soundcharts](#) *Qué son:* plataformas de analítica musical que usan managers y cazatalentos de sellos para seguir artistas. *Para qué nos sirven:* son el **contexto profesional** del usuario. Muestran a qué está acostumbrado alguien que trabaja en la industria.

Musiio, Music Xray y la llamada "hit song science" *Qué son:* empresas que venden predicción de éxito. Te dicen "tu canción tiene 74% de chances de ser un hit". *Por qué están acá:* son el **contraejemplo deliberado**, y es el mejor argumento de posicionamiento del proyecto. Ellos venden una **certeza**; P&P vende un **diagnóstico con una tensión adentro**, con márgenes explícitos y un asistente que admite lo que no sabe. Decirlo así en la presentación deja clarísimo qué hace distinto al proyecto.

Inteligencia artificial sobre datos propios

[Perplexity](#) *Qué es:* un buscador conversacional donde cada afirmación viene con el link a la fuente de donde salió. *Qué le tomamos:* que el asistente **cite el dato concreto** en que se apoya. Si dice "tu duración te suma

en prestigio", tiene que poder mostrar de dónde sale ese número.

Hex — función Magic *Qué es:* una herramienta de análisis de datos donde la IA propone el análisis, pero el código que genera queda a la vista y se puede editar. *Por qué es el referente clave de arquitectura:* es exactamente el modelo que planteamos — el modelo calcula, la IA traduce, y el cálculo queda auditable. Es lo que hace que el asistente de P&P no sea "un ChatGPT pegado al costado", y es defendible frente a cualquier pregunta de la cátedra.

B.3 Glosario

API — la forma en que un programa le pide datos a otro por internet. Spotify tenía una para las características de sonido; la cerró en 2024.

Corpus — el conjunto completo de canciones con las que el sistema aprende.

CSV — un archivo de tabla en texto plano, donde las columnas se separan con comas. Se abre con Excel.

Dataset — un archivo con datos ordenados en filas y columnas, como una planilla pero mucho más grande.

Dump — una copia completa de una base de datos, publicada como archivo para que otros la usen.

Entrenar un modelo — mostrarle al sistema miles de ejemplos con la respuesta puesta, para que aprenda solo qué combinaciones llevan a cada resultado.

Feature / característica — una columna que describe algo medible de una canción. "Energía = 0,73" es una característica.

Grupo de control — el conjunto de ejemplos "comunes", los que no tienen nada especial. Sirve para que el sistema sepa contra qué comparar.

Loudness war — la tendencia de la industria, desde los 90, a masterizar los discos cada vez más fuerte. Hace que las grabaciones de distintas épocas no sean comparables sin ajuste.

Margen de error — cuánto puede equivocarse una estimación. "32%, entre 24% y 41%" dice que el valor real probablemente esté en ese rango.

Matching / cruce — juntar dos tablas identificando qué fila de una corresponde a qué fila de la otra. Acá: reconocer que "Blinding Lights" en Billboard y "Blinding Lights - Remastered" en el dump son la misma canción.

Normalizar — dos sentidos distintos. Con textos: dejarlos en forma estándar (minúsculas, sin acentos) para poder compararlos. Con números: medir cuánto se aparta un valor de su referencia, en vez de usar el valor crudo.

Parquet — un formato de archivo pensado para tablas enormes. Ocupa menos que un CSV y se consulta más rápido.

Parsear — leer un texto desordenado y extraer de ahí datos ordenados. Lo que hicimos con las páginas de Wikipedia.

Script — un programa corto que hace una tarea concreta. Los nuestros están en `pyp/scripts/`.