

Guía de los cuatro archivos de datos

Para alguien que abre la carpeta **PyP-datos** y no sabe nada del proyecto.

Explica qué es cada archivo, de dónde salió, qué tiene adentro y cómo leerlo. No hace falta saber nada de programación ni de datos.

7 de septiembre de 2026

Antes que nada: qué es este proyecto

P&P (Prestigio & Popularidad) es una aplicación web donde un músico sube su canción y recibe dos puntajes:

- **Prestigio** — cuánto se parece al tipo de canción que el Grammy premia
- **Popularidad** — cuánto se parece al tipo de canción que triunfa comercialmente

La idea de fondo es que **esos dos mundos casi nunca coinciden**. Hay canciones que ganan premios y canciones que llenan estadios, y rara vez son las mismas. La app no predice nada: te muestra dónde está parada tu canción entre esos dos polos, y qué la acerca o la aleja de cada uno.

Y por qué hacen falta estos archivos

Para que la app pueda decir "*tu canción se parece un 32% al perfil del Grammy*", primero hay que enseñarle **cómo suena** cada uno de esos dos mundos.

Se le enseña igual que se le enseñaría a una persona a distinguir vinos: no con teoría, sino haciéndole probar **miles de ejemplos con la respuesta puesta**. Esta canción ganó un Grammy. Esta fue un hit. Esta no fue ninguna de las dos.


Estos cuatro archivos son esos ejemplos.

Los cuatro archivos, de un vistazo

Archivo	Filas	Qué es
billboard-canciones.csv	32.702	Todas las canciones que entraron al ranking de más escuchadas de EE.UU. desde 1958
grammy-nominaciones.csv	2.514	Todas las nominaciones al Grammy desde 1959
corpus-v2.csv	26.577	El archivo principal. Las dos listas anteriores, ya cruzadas y con las características del sonido de cada canción
control-v2.csv	27.000	Canciones comunes: ni premiadas ni exitosas. Sirven de punto de comparación

Los dos primeros son las materias primas. Los dos últimos son el producto terminado, y son los que usa el sistema para aprender.

Cómo se relacionan



Los dos archivos finales tienen **exactamente las mismas columnas**, así que se pueden juntar en una sola tabla: **53.577 canciones** en total para que el sistema aprenda.

Archivo 1 — billboard-canciones.csv

32.702 filas · 6 columnas · 1,5 MB

Qué es

El **Billboard Hot 100** es el ranking semanal de las 100 canciones más escuchadas en Estados Unidos. Existe sin interrupción desde agosto de 1958, y es la referencia de éxito comercial más antigua y más consistente que hay.

Este archivo tiene **una fila por canción**, con el resumen de todo su paso por ese ranking.

De dónde salió

De un repositorio público en GitHub que lo mantiene actualizado. Descarga directa, gratis, sin cuenta.

El archivo original tiene **355.001 filas**, porque registra cada canción **una vez por semana**: si una canción estuvo 30 semanas en el ranking, aparece 30 veces. Lo resumimos a una fila por canción.

Las columnas

Columna	Qué dice	Ejemplo
<code>titulo</code>	Nombre de la canción	Blinding Lights
<code>artista</code>	Quién la canta	The Weeknd
<code>mejor_puesto</code>	El puesto más alto que alcanzó, de 1 a 100	1
<code>semanas_en_chart</code>	Cuántas semanas estuvo en el ranking	90
<code>anio_primera_aparicion</code>	El año en que entró por primera vez	2019
<code>apariciones</code>	Cuántas veces figura en el archivo original	90

Qué mirar si lo abris

- `mejor_puesto` = 1 significa que fue número uno del país. Hay **1.196** canciones así en toda la historia.
- `semanas_en_chart` es la medida de cuánto duró el éxito. El récord del archivo son **112 semanas**, más de dos años.
- Un puesto 1 con 4 semanas y un puesto 12 con 60 semanas son éxitos muy distintos. Por eso guardamos las dos columnas y no solo el puesto.

Por qué Billboard y no la cantidad de reproducciones en Spotify. Es la decisión más importante de todo el proyecto. Las reproducciones existen desde 2015 más o menos: **no hay forma de saber cuántas veces se reprodujo una canción en 1967**. Billboard es la única medida de éxito comercial que existe en las seis décadas que queremos comparar, y siempre se midió igual.

Archivo 2 — `grammy-nominaciones.csv`

2.514 filas · 5 columnas · 147 KB

Qué es

Todas las canciones **nominadas** al Grammy —no solo las ganadoras— entre 1959 y 2026, en 14 categorías.

Cada fila es una **nominación**. Si una canción fue nominada en tres categorías, aparece tres veces.

De dónde salió

Lo armamos nosotros. Buscamos listas ya hechas y ninguna servía: las de Kaggle exigen crear una cuenta y varias traen solo ganadores, y la mejor que encontramos en GitHub solo cubría del 2000 al 2022.

Wikipedia tiene una página por cada categoría del Grammy, con una tabla de todos los años y todos los nominados. Escribimos un programa que baja esas páginas y las convierte en tabla. Es gratis, no pide cuenta, y es la fuente más completa que existe para los años viejos.

Las columnas

Columna	Qué dice	Ejemplo
anio	Año de la ceremonia	1959
categoria	En qué categoría compitió	Record of the Year
titulo	Nombre de la canción	Nel Blu Dipinto Di Blu (Volare)
artista	Quién la canta	Domenico Modugno
ganador	1 si ganó, 0 si solo fue nominada	1

Las 14 categorías

Categoría	Nominaciones
Song of the Year	370
Record of the Year	367
Best Country Song	317
Best R&B Song	291
Best Alternative Music Album	178
Best Rock Song	177
Best Metal Performance	175
Best Melodic Rap Performance	126
Best Rap Song	116
Best Rap Performance	88
Best Rock Performance	80
Best Pop Solo Performance	77
Best Pop Duo/Group Performance	76
Best Country Solo Performance	76

Las dos primeras son distintas de todas las demás. *Record of the Year* y *Song of the Year* premian una canción **sin importar el género**: son las que representan el gusto general de la Academia. Las otras doce premian dentro de un estilo.

Esa diferencia importa: si uno mide "lo que premia la Academia" mezclando todas las categorías, el resultado sale distorsionado. El metal es ruidoso por definición, así que meterlo en la misma bolsa que una balada no mide prestigio, mide que el metal es ruidoso.

Qué mirar si lo abris

- De las 2.514 nominaciones, **488 ganaron**.
- La primera fila es de 1959: *Volare*, de Domenico Modugno, ganadora de Record of the Year en la primera entrega de la historia.

Por qué nominados y no solo ganadores. Ganadores de Canción del Año hay unos **60 en toda la historia**. Con 60 ejemplos un sistema no aprende nada: se los memoriza y después falla con todo lo demás. Sumando los nominados pasamos de 60 a 2.514, **cuarenta veces más material**. Y es más

correcto: una nominación ya es reconocimiento de la Academia. Que gane una de las cinco finalistas depende de campaña, sello y política, cosas que ningún dato sobre el sonido puede capturar.

Archivo 3 — `corpus-v2.csv` ← el principal

26.577 filas · 21 columnas · 3,1 MB

Qué es

El archivo más importante de los cuatro. Es el resultado de cruzar los dos anteriores contra una base de 56 millones de canciones que tiene, para cada una, **números que describen cómo suena**.

Cada fila es una canción con tres cosas juntas:

1. **Quién es** — título, artista, año
2. **Qué le pasó** — si ganó o fue nominada al Grammy, y qué puesto alcanzó en Billboard
3. **Cómo suena** — diez números que describen su sonido

Esa combinación es la que permite que el sistema encuentre el patrón.

Los cuatro grupos

La columna `grupo` resume de un vistazo qué es cada canción:

Grupo	Canciones	Qué son
<code>hit</code>	24.913	Entraron al ranking, nunca fueron nominadas
<code>ambas</code>	1.071	Premio y éxito a la vez. Las raras
<code>premiada</code>	593	Nominadas al Grammy, nunca entraron al ranking

Ese grupo `ambas` de 1.071 canciones es interesante por sí solo: es la prueba de qué tan poco frecuente es lograr las dos cosas.

Las columnas

Identidad y resultados (las primeras diez):

Columna	Qué dice
<code>titulo</code> , <code>artista</code> , <code>anio</code>	Quién es y de cuándo
<code>grammy_gano</code>	1 si ganó, 0 si no
<code>grammy_nominada</code>	1 si fue nominada, 0 si no
<code>grammy_categorias</code>	En qué categorías compitió
<code>mejor_puesto</code>	Su mejor posición en Billboard
<code>semanas_en_chart</code>	Cuántas semanas duró en el ranking
<code>fue_hit</code>	1 si entró alguna vez al ranking
<code>grupo</code>	<code>hit</code> , <code>ambas</code> o <code>premiada</code>

Cómo suena (las últimas once) — ver la sección siguiente.

Un ejemplo real del archivo

```

titulo      Nasty
artista     Ariana Grande
anio        2020
grupo       hit
mejor_puesto 49      ← llegó al puesto 49
semanas_en_chart 1    ← duró una sola semana
grammy_nominada 0     ← no fue nominada
energy       0.506
valence      0.456    ← ni alegre ni triste
danceability 0.772    ← muyailable
duration_ms 200732    ← 3 minutos 20 segundos

```

Archivo 4 — `control-v2.csv`

27.000 filas · 21 columnas · 3,3 MB

Qué es

Canciones **comunes**: no ganaron nada y nunca fueron un éxito. Tiene exactamente las mismas columnas que el archivo anterior.

Por qué existe — y es lo que más cuesta explicar

Parece que con los premiados y los exitosos ya alcanzaría. **No alcanza.**

Si al sistema solo le mostramos canciones ganadoras y canciones exitosas, **nunca ve cómo suena una canción normal**, y entonces no tiene contra qué comparar. Todo lo que le entre va a puntuar alto en algo.

Es como enseñarle a alguien a reconocer caras famosas mostrándole únicamente fotos de famosos. Cuando le muestres a un desconocido, va a decir que también es famoso — porque nunca vio cómo se ve alguien que no lo es.

Sin este archivo, los dos puntajes de la app **no significarían nada**. Y lo peor es que no se notaría: los números saldrían, se verían razonables, el gráfico se dibujaría bien. El error sería invisible desde la pantalla.

De dónde salieron

De la misma base de 56 millones de canciones. Todas las que están ahí y **no** aparecen ni en Billboard ni en Grammy son, por definición, canciones que no ganaron ni fueron hit. De esas quedaron 8,9 millones de candidatas, y tomamos **4.500 por década desde 1970**, para que ninguna época domine.

Un detalle que hubo que resolver

La base de Spotify no tiene solo música: tiene **audiolibros, ruido blanco para dormir, y grabaciones de meditación**. En el primer intento se coló un audiolibro infantil alemán y un track de sonidos para dormir bebés.

Eso habría arruinado todo: el sistema habría aprendido que "no ser un hit" significa "ser palabra hablada", que es facilísimo de detectar. Se habría visto muy preciso y habría sido completamente inútil.

Se filtró: fuera lo que tiene más de dos tercios de palabra hablada, lo que dura menos de un minuto o más de quince, y los artistas de fábrica tipo "*White Noise Baby Sleep*".

Un ejemplo real del archivo

titulo	Everybody Wants to Rule the World	
artista	No BS! Brass	← una banda de bronce, no Tears for Fears
año	2017	
grupo	control	
mejor_puesto	(vacío)	← nunca entró al ranking
semanas_en_chart	0	
grammy_nominada	0	
energy	0.545	
instrumentalness	0.782	← casi sin voz, es instrumental

Las once columnas de sonido

Estas son las que aparecen en los dos archivos grandes. Casi todas van de 0 a 1, donde 0 es nada y 1 es el máximo.

Antes que nada: ¿quién analizó las canciones?

Es la pregunta que más se hace y conviene tenerla clara: **nosotros no analizamos ninguna canción. El análisis lo hizo Spotify.**

La cadena, en cuatro pasos:

1. **Spotify analizó el audio.** Durante años su sistema procesó cada canción de su catálogo y calculó automáticamente estos valores — energía, valencia, acústica y el resto. Lo hacía para sus propias recomendaciones, no para nosotros.
2. **Los publicaba por su API.** Cualquier programador podía preguntarle "dame las características de esta canción" y Spotify devolvía los números.
3. **Alguien los cosechó.** Un usuario de HuggingFace le pidió a esa API los datos de millones de canciones y armó una tabla con todo. Ese es el archivo que bajamos.
4. **En noviembre de 2024 Spotify cerró el acceso.** Las aplicaciones nuevas ya no pueden pedir esos datos. Por eso ese archivo es la única vía que queda: es una foto tomada antes del cierre.

Cómo decirlo con precisión. El archivo de origen tiene 56 millones de canciones, pero eso es el tamaño de la fuente, no de nuestro trabajo: usamos 8,9 millones como referencia de época y 53.577 como material de aprendizaje. Decir "analizamos 56 millones de canciones" sería falso, y la primera pregunta sobre cómo se hizo eso en una computadora dejaría sin respuesta.

Y una limitación honesta: nunca pudimos verificar el algoritmo de Spotify. Confiamos en que su "energía 0,82" mide lo que dice medir, pero es una caja negra — nunca publicaron cómo lo calculan. Si alguien pregunta "¿cómo se calcula la energía?", la respuesta correcta es "con el método propietario de Spotify, que no es público".

Las columnas, una por una

Están ordenadas por cuánto sirven para distinguir una canción premiada de un hit — eso está medido, no supuesto:

Columna	Qué mide, en criollo	Ejemplo	Sirve
energy	Qué tan intensa y activa suena	Metal $\approx 0,95$ · balada de piano $\approx 0,15$	mucho
valence	Qué tan alegre suena. No la letra: el sonido	Canción de fiesta $\approx 0,9$ · melancólica $\approx 0,2$	mucho
acousticness	Si usa instrumentos reales o electrónicos	Guitarra y voz $\approx 0,9$ · electrónica $\approx 0,02$	bastante
duration_ms	Cuánto dura, en milésimas de segundo	200.000 = 3 min 20 s	bastante
danceability	Qué tan regular y marcado es el ritmo	Reguetón $\approx 0,85$ · rock progresivo $\approx 0,3$	algo
loudness	Volumen promedio en decibeles. Es negativo: cuanto más cerca de cero, más fuerte	Pop moderno ≈ -5 · grabación de los 60 ≈ -13	algo
speechiness	Cuánta palabra hablada tiene, en vez de cantada	Rap $\approx 0,3$ · pop $\approx 0,04$	algo
tempo	Velocidad, en pulsos por minuto	Balada ≈ 70 · house ≈ 128	poco
mode	1 si está en modo mayor, 0 si es menor	Mayor suele sonar alegre; menor, triste	casi nada
instrumentalness	Probabilidad de que no tenga voz cantada	Instrumental $\approx 0,9$ · canción normal $\approx 0,0$	casi nada
rareza	Calculada por nosotros. Cuán distinta es de todo lo que se publicó ese año	0,5 = del montón · 2,0 = muy rara	poco

Las cuatro primeras son las que explican el resultado. Las canciones premiadas son, en promedio, **menos** enérgicas, más melancólicas, más acústicas y más largas que los hits. Eso es el hallazgo central del proyecto, y sale de estas cuatro columnas.

Sobre la rareza. La agregamos para probar una idea propia: que quizá la Academia premia lo que se sale de la norma. **No se sostuvo** — las premiadas son igual de comunes que los hits. Es un resultado negativo y lo dejamos escrito como tal. La columna se queda porque igual es información interesante para el usuario: "tu canción es más rara que el 90% de lo que se publicó este año" es algo que un músico quiere saber.

Sobre las celdas vacías

Al abrir los archivos en Excel se ven columnas con celdas en blanco. **Ninguna es un error.** Cada una está vacía por un motivo:

Columna	Vacía en	Por qué
grammy_categorias	Todo el control, y el 94% del corpus	Son canciones que nunca fueron nominadas . No hay categoría que poner
mejor_puesto	Todo el control, y 593 del corpus	Son canciones que nunca entraron al ranking . Dejarlo vacío es lo correcto: poner un 0 o un 101 sería inventar una posición que no existe
rareza	6.156 del corpus (23%)	Son las anteriores a 1970 . La rareza se mide comparando contra la música de cada año, y para los años viejos no tenemos una referencia confiable

Una distinción que vale la pena: **semanas_en_chart** dice 0, no está vacía. Es a propósito. Vacío significa "no sabemos"; cero significa "sabemos que fue ninguna". Una canción que nunca entró al ranking efectivamente estuvo cero semanas ahí, y eso es un dato.

Cómo verificar que los archivos están bien

Si querés comprobarlo por tu cuenta, abrílos en Excel y mirá esto:

1. **corpus-v2.csv** — **filtrá por grupo**. Tienen que aparecer exactamente tres valores: **hit** (24.913), **ambas** (1.071) y **premiada** (593).
2. **control-v2.csv** — la columna **grupo** tiene que decir **control** en las 27.000 filas, y **grammy_nominada** y **fue_hit** tienen que ser 0 en todas.
3. **Buscá una canción que conozcas** en **corpus-v2.csv**. Si buscás *Rolling in the Deep* de Adele, tiene que figurar como **ambas**, con **mejor_puesto** 1 y **grammy_gano** 1.
4. **Los años**. El corpus va de 1958 a 2026; el control, de 1970 a 2025.

Nota para Excel: los números usan **punto** decimal (0.506, no 0,506) porque salieron de una herramienta en inglés. Si Excel te los muestra como texto o los convierte en fechas, importalos con *Datos → Obtener datos → Desde archivo de texto* eligiendo el punto como separador decimal.

Glosario

CSV — un archivo de tabla en texto plano, donde las columnas se separan con comas. Se abre con Excel haciendo doble clic.

Corpus — el conjunto de canciones con las que el sistema aprende.

Grupo de control — el conjunto de ejemplos comunes, los que no tienen nada especial. Sirve para que el sistema sepa contra qué comparar.

Billboard Hot 100 — el ranking semanal de las 100 canciones más escuchadas en Estados Unidos. Existe desde 1958.

Nominación — que la Academia haya elegido una canción entre las finalistas de una categoría, haya ganado o no.

Valencia — qué tan alegre suena una canción. No la letra: el sonido. Va de 0 a 1.

Milisegundos — milésimas de segundo. `duration_ms = 200000` son 200 segundos, o sea 3 minutos y 20.